



1. Grande Vision d'Ensemble
2. Algorithmes célèbres de ML
  - **Machines à Vecteurs de support (Support Vector Machines SVM)**
  - Arbres de décision (Decision Trees)
  - Forêts aléatoires (Random Forest)
  - Autres algorithmes
  - Quel algorithme choisir ?

# SVM


Support Vector machines





Quelle est la  
meilleur frontière  
de décision?

Si on rajoute des exemples ...





Quelle est la  
meilleur frontière  
de décision?

Qu'est ce qui fait  
qu'une frontière  
de décision est la  
meilleure??

Remarquons que:

- une **mauvaise frontière** de décision induit une mauvaise **généralisation**.
- La meilleur droite est celle qui est la plus éloignée des exemples




Remarquons que:  
La frontière de décision la **plus éloignés possible** des exemples **positifs** et **négatifs** est celle avec **la plus grande marge entre les deux classes**.

Un des plus **performants** et des plus **populaires** algorithms de **Classification**!



Comme pour la Régression Logistique, SVM construit un **hyperplan** qui sépare la classe **positive** de la classe **négative**

La frontière de décision de SVM a la particularité d'être la **plus éloignés possible** des exemples **positifs** et **négatifs**:  
**Maximum de marge entre les deux classes**

2-dimensions:  
Hyperplan = une ligne



3-dimensions:  
Hyperplan = un plan




# Support Vector Machines (SVM)

- Un des **plus performants** et des **plus populaires** algorithmes de **classification**.


Principe de Fonctionnement de SVM:

1. Construit un **hyperplan** qui sépare les deux classes
2. **Maximum de marge** entre les deux classes
3. S'appuie sur certains vecteurs (**support vectors**)
4. Paramètre **C**
5. **Frontières non linéaires** grâce au noyaux (kernels)




# (1) Frontière de Décision en Hyperplan

1-dimension:  
Hyperplan = un point




A hyperplane in  $\mathbb{R}^2$  is a line



2-dimensions:  
Hyperplan = une ligne

A hyperplane in  $\mathbb{R}^3$  is a plane


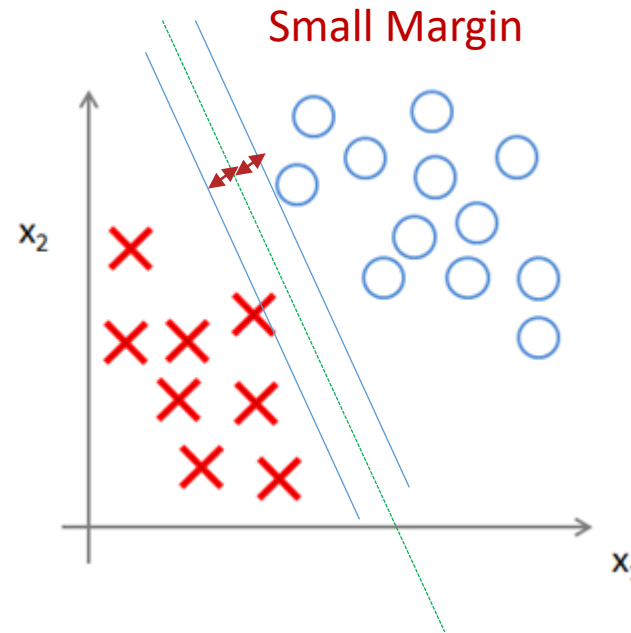



3-dimensions:  
Hyperplan = un plan

Comme pour la Régression Logistique, SVM construit un **hyperplan** qui sépare la classe **positive** de la classe **négative**






# SVM – (2) Maximum de Marge





La frontière de décision de SVM a la particularité d'être la **plus éloignés possible** des exemples **positifs** et **négatifs**

### (3) Vecteurs de support (Support Vectors)



**Vecteurs de support:** les points les plus proches de l'hyperplan et qui influencent sa position et son orientation.


### (3) Vecteurs de support (Support Vectors)



- **Uniquement** la position des vecteurs de support affecte la frontière de décision.
- Tout les autres points (et qui sont dans le bon côté) n'affectent pas la frontière de décision
- Une autre **force** de **SVM**: La **non-sensitivité aux points distants**!


## (4) Paramètre C

- Quelle est la meilleur frontière de décision?




**Intuition:** tolérer des erreurs de classification pour une meilleure frontière de décision

## (4) Paramètre C



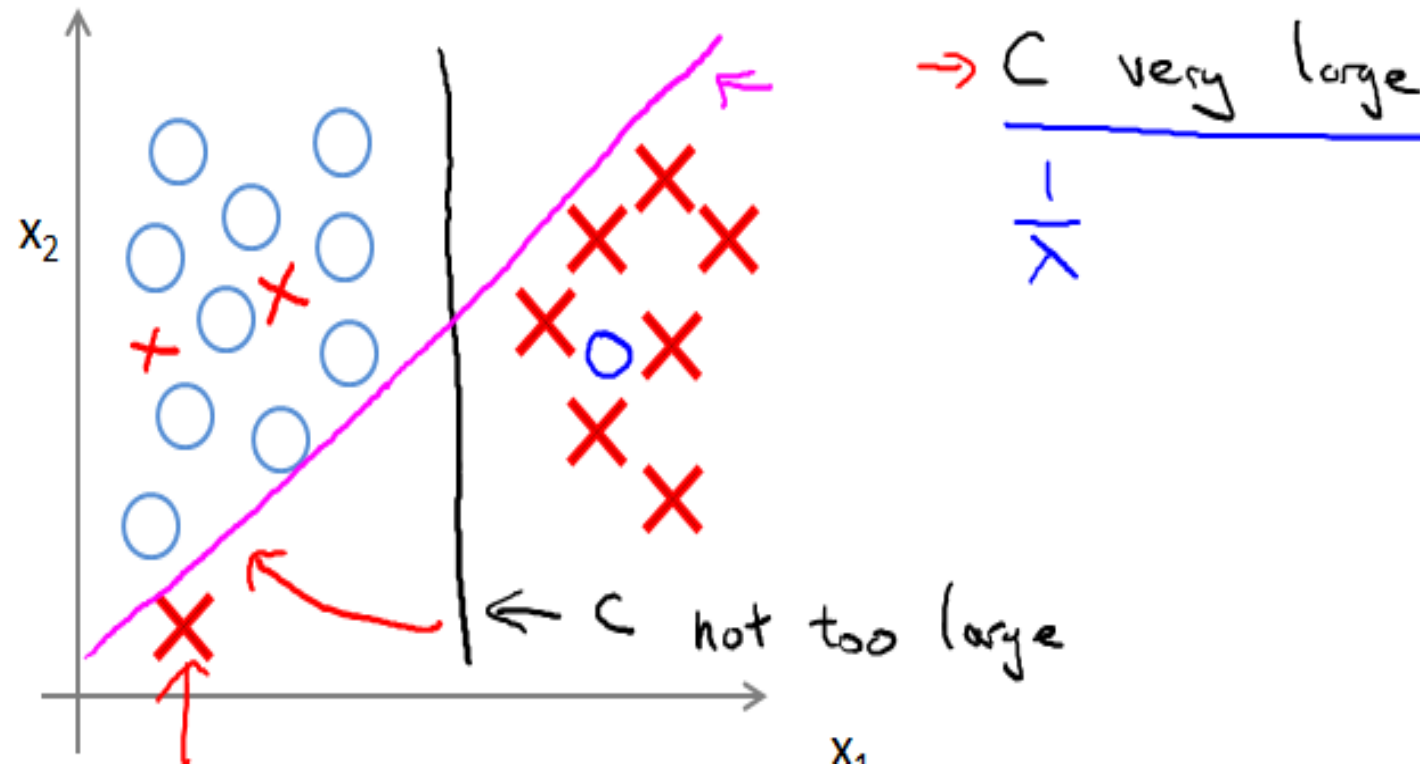
Large value for  
parameter C





Small value for  
parameter C

- **Paramètre C** : Permet de considérer ou non la 'misclassification'.
- Equivalent à  $1/\lambda$  ( $\lambda$  est la force de regularisation)
- Un **petit C** permet de tolérer des erreurs de classifications
- Un **grand C** respecte la contrainte de marge maximale mais avec zero erreurs.
- Un **petit C** viole la contrainte de marge maximale.

## (4) Paramètre C



## (4) Paramètre C





## (4) Paramètre C

### **SVM à marge dure (Hard Margin) :**

- chaque point de données doit être classé correctement.
- Plus sensible aux données bruitées et aux valeurs aberrantes.
- Peut ne pas généraliser correctement.


### **SVM à marge souple (Soft Margin) :**

- peut tolérer un certain nombre d'erreurs de classification.
- Plus robuste aux données bruitées et aux valeurs aberrantes.
- Meilleure généralisation.





## (5) Noyaux de SVM

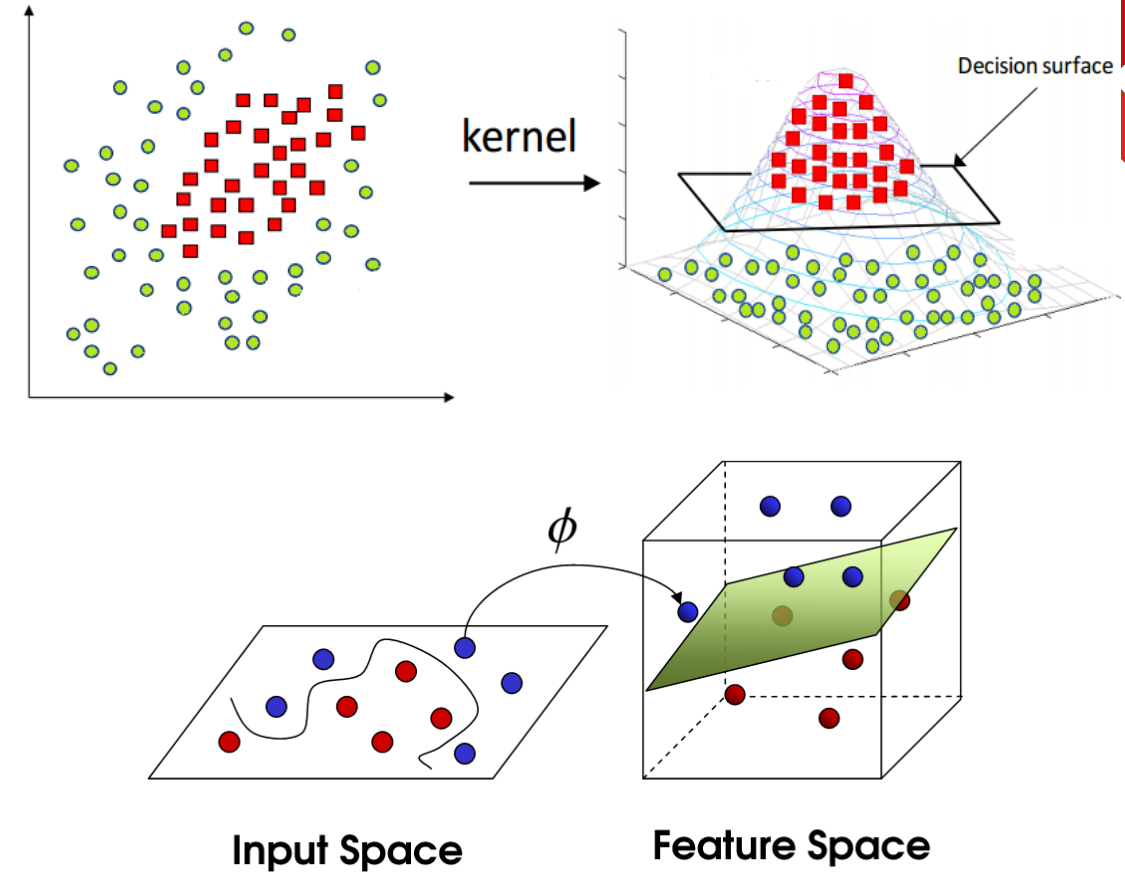



Données non-linéairement séparables:  
Comment tracer l'**hyperplan** frontière de décision?



## (5) Noyaux de SVM


On rajoute une nouvelle dimension  $x_2 = x^2$



Objectif: transformer les données dans un **nouvel espace** (dit **espace caractéristique étendu**) de sorte à ce qu'elles deviennent **linéairement séparables** !

## (5) Noyaux de SVM - Astuce du Noyau (kernel Trick)

- **Problème:** La transformation de données dans de nouvelles dimensions peut être très coûteuse en calculs, surtout quand le nombre de caractéristiques est élevé.
- **Solution:** **Astuce du Noyau (Kernel trick)**







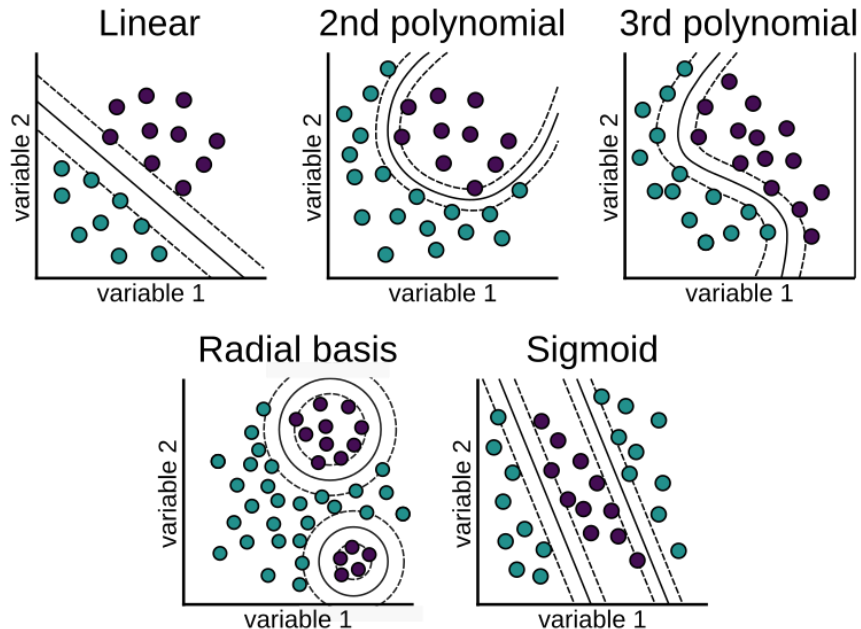
## (5) Astuce du Noyau

- Un noyau (kernel) est une fonction qui calcule le produit scalaire entre deux vecteurs dans l'espace de caractéristiques étendu.
- **Astuce du noyau de SVM:** consiste à calculer les produits scalaires dans l'espace étendu sans avoir à effectuer explicitement les transformations vers cet espace.
- Les calculs sont réduits
- Séparation non linéaire dans les dimensions d'origine!

# (5) Noyaux de SVM






Les noyaux couramment utilisés :

- noyau linéaire,
- noyau polynomial
- noyau gaussien (RBF)
- sigmoïd




# (5) Noyaux de SVM


| Kernel function                             | Expression                                    | Parameter    |
|---|---|--------------|
| Liner kernel function                       | $K(x_i, x_j) = x_i \cdot x_j$                 |              |
| Polynomial kernel function                  | $K(x_i, x_j) = (x_i \cdot x_j + 1)^d$         | $d$          |
| Radial basis function (RBF) kernel function | $K(x_i, x_j) = \exp(-\gamma \ x_i - x_j\ ^2)$ | $\gamma > 0$ |
| Sigmoid kernel function                     | $K(x_i, x_j) = \tanh(b(x_i, x_j) + c)$        | $b, c$       |



## (5) Noyaux de SVM - Astuce du Noyau (kernel Trick)



Support  
Vector  
Machine  
In 2 min



<https://www.youtube.com/watch?v= YPScrckx28>

Principe de Fonctionnement de SVM:

1. Construit un **hyperplan** qui sépare les deux classes
2. **Maximum de marge** entre les deux classes
3. S'appuie sur certains vecteurs (**support vectors**)
4. Paramètre **C**
5. **Frontières non linéaires** grâce au noyaux (**kernels**)